

# Clasificación de Series de Tiempo Astronómicas

Muriel Pérez  
201011755

30 de abril de 2015



# Índice general

<b>1. Introducción</b>	<b>5</b>
<b>2. El Problema del Aprendizaje</b>	<b>9</b>
2.1. Lulu . . . . .	9
2.2. El Clasificador de Bayes y Consistencia . . . . .	11
2.3. Estimación del Error . . . . .	14
2.4. Clasificadores . . . . .	15
2.4.1. K Vecinos Más Cercanos . . . . .	15
2.4.2. Máquinas de Soporte Vectorial . . . . .	16
2.4.3. Árboles de Clasificación y Regresión . . . . .	25
2.4.4. Bosques Aleatorios . . . . .	26
<b>3. Clasificación</b>	<b>27</b>
3.1. El conjunto de Datos . . . . .	29
3.2. Características Seleccionadas . . . . .	31
3.3. Clasificación . . . . .	37
3.3.1. K Vecinos Más Cercanos . . . . .	37
3.3.2. Árboles de clasificación y regresión . . . . .	37
3.3.3. Máquinas de Soporte Vectorial . . . . .	37
3.3.4. Bosques Aleatorios . . . . .	37



# Capítulo 1

## Introducción

Con los avances en técnicas de observación astronómica que han sucedido en los últimos años, hay grandes cantidades de datos disponibles. Por ejemplo se espera que el *VISTA Variables in the Via Lactea* (VVV) del *European Southern Observatory* (ESO) produzca del orden de  $10^9$  curvas de luz<sup>1</sup> de fuentes puntuales en el infrarojo cercano con hasta 100 observaciones en diferentes épocas de alta calidad. De la misma forma estudios como la misión Kepler de la *National Aeronautics and Space Administration* (NASA), cuyo objetivo principal es la detección de exoplanetas, tienen como subproductos gran cantidad de curvas de luz.

Para que estos datos sean útiles para la comunidad científica es necesario clasificarlos y extraer sus características. Aunque los métodos automáticos muchas veces no pueden igualar la inspección manual por parte de un experto, la cantidad de datos disponible hace que esta tarea no sea posible en corto tiempo y hace necesario utilizar técnicas de minería de datos. Este interés se manifiesta en proyectos como el *VVV Templates Project* que tiene como objetivo consolidar una base bien definida de curvas de luz de estrellas variables en el infrarojo cercano para ser utilizadas como referencia para la clasificación automática de curvas de luz.

Las curvas de luz no pueden ser analizadas con técnicas de análisis de series de tiempo porque, debido a limitaciones en el tiempo de observación, fallas técnicas, periodos de mantenimiento de los instrumentos utilizados y

---

<sup>1</sup> La curva de luz de una estrella es el resultado de medir su magnitud como función del tiempo. La magnitud de una estrella es el flujo de energía observado en una parte del espectro electromagnético (una banda), delimitada por un filtro, en escala logarítmica (ver el capítulo 4 de [15]).

la imposibilidad de observar todas las regiones del cielo durante todo el año, las curvas de luz no constan del mismo número de observaciones y éstas no son hechas en intervalos regulares por lo que el tiempo durante el cual cada estrella no es observada es impredecible y algunas características importantes de las curvas de luz no son observadas.

Dependiendo de la serie de magnitudes observadas, una estrella puede ser clasificadas como variable o no variable; periódicas o no periódicas; y en diferentes clases de variabilidad estelar que depende de la morfología de su curva de luz. La forma de la curva de luz depende de las condiciones físicas de la estrella por lo que conocer a qué tipo de variabilidad pertenece cada estrella es de vital importancia para el estudio de las estrellas variables. A su vez, el estudio de las estrellas variables ha sido importante para el estudio de la evolución estelar, la determinación de distancias cósmicas y la búsqueda de exoplanetas, entre otras.

En estudios previos [11, 25, 20] se le ha asignado a cada curva de luz un vector, llamado vector de características, y, basado en él, se ha hecho la clasificación automática. Este proceso consiste en entrenar un clasificador basado en una muestra clasificada previamente, la muestra de entrenamiento, utilizando el vector de características escogido. La escogencia de el vector de características es crucial para el proceso de clasificación porque con él se debe poder clasificar cada curva de luz, es decir, debe lograr que, en el espacio de características, las clases se superpongan lo menos posible. Para la conformación de este vector se han elegido coeficientes de Fourier de la curva de luz [11, 25, 20], que son calculados mediante métodos como el periodograma de Lomb-Scargle [26] o la minimización de la entropía de Shannon de la gráfica de la curva [8].

Esta elección de características no es del todo conveniente porque requiere de gran poder computacional y limita el tipo de objetos que pueden ser clasificados. El cálculo del periodogramas como el de Lomb-Scargle para curvas de luz, y en general el de los métodos utilizados en la literatura, requiere de intentar una gran cantidad de periodos candidatos a ser el periodo de la curva de luz para luego elegir el mejor y de la inspección manual de las curvas de luz. Los periodos de los objetos observados varía entre desde unos pocos minutos y varios años por lo cual se requiere probar una gran cantidad de periodos. Por un lado este es un proceso es computacionalmente intensivo, lo que limita su uso en conjuntos grandes de curvas de luz; y por otro lado no es seguro que dé como resultado el periodo real de una curva de luz, por lo que a menudo éste debe ser revisado manualmente. Además el resultado de

la clasificación puede ser sensible a la calidad de las curvas de luz que sean elegidas como muestra de entrenamiento [11] y limita el estudio a fuentes periódicas.

En [21, 23], los autores notaron que algunas variables descriptivas de la serie de magnitudes de una curva de luz (como su sesgo o su curtosis) sirven para clasificar ciertos tipos de estrellas con clasificadores lineales. En este trabajo retomamos esa idea y construimos un vector de características basadas en variables tomadas de estadística descriptiva. El uso de este tipo de variables tiene las ventajas de que puede ser calculadas de manera rápida y da como resultado un vector de características que sirve para realizar clasificación con una tasa de éxito alta. Para evaluar esta aproximación al problema utilizamos una parte del Catálogo de Estrellas Variables de la tercera fase del *Optical Gravitational Lensing Experiment* (OGLE III)[29, 34, 36, 32, 31, 30, 40, 39, 37, 18, 14, 19, 33, 38, 35] que contiene curvas de luz de estrellas previamente clasificadas en seis tipos de variabilidad estelar y curvas de luz de estrellas candidatas a ser clasificadas como Be (ver cuadro 3.1).

En este trabajo utilizamos k-vecinos más cercanos, árboles de clasificación, máquinas de soporte vectorial y bosques aleatorios para realizar la clasificación automática de las curvas de luz basada en nuestra elección de características. Asimismo, estimamos la probabilidad de que una nueva curva de luz sea clasificada correctamente por uno de estos clasificadores utilizando validación cruzada de 10 iteraciones. Estos clasificadores fueron elegidos porque son aproximaciones muy distintas al problema de clasificación, por su naturaleza no lineal y no paramétrica; y por el hecho de que han mostrado ser efectivos en gran cantidad de aplicaciones prácticas. Para todo el análisis utilizamos el paquete estadístico de fuente abierta *R* (cita de R). Para cada tarea utilizamos paquetes específicos que son referenciados a lo largo del documento.

Este documento está organizado de la siguiente forma. En el capítulo 3.1 damos una descripción del conjunto de datos utilizado en este trabajo. En el capítulo 3 abordamos el problema de clasificación de manera informal, presentamos y discutimos la elección de atributos y evaluamos el desempeño de los clasificadores mediante validación cruzada de 10 iteraciones. En los apéndices abordamos formalmente el problema de aprendizaje en general y damos una descripción de cada uno de los algoritmos utilizados en el trabajo.





# Capítulo 2


## El Problema del Aprendizaje

Aquí diré cómo está organizado el capítulo.

### 2.1. Lulu

Las personas reconocemos con facilidad las letras en manuscritos, las caras de otras personas, las palabras que alguien nos dice o el estado de la comida basado en su olor. La capacidad de agrupar los estímulos que recibimos en categorías, por ejemplo el olor de la comida en buen o mal estado, y la capacidad para actuar en respuesta a ellos ha sido de vital importancia para nuestra supervivencia. Por ello hemos desarrollado complejos sistemas para llevar a cabo estas tareas.

Con la popularización de computadores electrónicos, la construcción máquinas que aprendan de la experiencia ha sido objeto de estudio. La habilidad de crear estas máquinas tiene una importancia estratégica puesto que existen tareas que no pueden ser llevadas a cabo utilizando técnicas de programación clásicas porque no existe un modelo matemático para ellas. En el caso de la clasificación de curvas de luz, por la forma en que se hacen las observaciones y el hecho de que la identificación de una curva de luz se hace con base en su forma, es difícil hacer un modelo matemático que capture estas diferencias. A pesar de esto existe gran cantidad de ejemplos de curvas de luz disponibles, por lo que es natural preguntarse si se puede entrenar un computador para identificar estas diferencias de la misma forma en que una persona puede ser entrenada para reconocerlas. En la figura 2.1 se observan dos curvas de luz, una pulsante y una eruptiva, que pueden ser distinguidas utilizando única-



(a) Curva de luz de una estrella Mira (b) Curva de luz de la Supernova 1987A

Figura 2.1: Las estrellas pueden ser clasificadas en grupos basados en la forma de sus curvas de luz. Esta clasificación puede ser hecha con base en la forma de las curvas de luz, sin embargo es difícil crear un modelo matemático que capture estas diferencias. Imágenes tomadas de [7]

mente esta información. La pregunta de si es posible entrenar un sistema basado en datos disponibles puede ser hecha para otras tareas, como el reconocimiento de textos en manuscritos, la detección e identificación de caras y objetos en imágenes o la identificación de genes en secuencias de ADN.

El reconocimiento de patrones es una disciplina científica cuya meta es la clasificación de objetos en clases. Existen situaciones en las cuales existe una gran cantidad de objetos previamente clasificados en clases predefinidas y la tarea es encontrar, o aproximar lo mejor posible, la dependencia funcional entre objetos y clases. Podemos precisar esto de la siguiente forma. Llamemos al espacio de los objetos que queremos clasificar  $X$  y  $\{1, \dots, M\}$  es el conjunto de las posibles clases a las que pueden pertenecer los elementos de  $X$ . En el caso de la clasificación de curvas de luz,  $X$  consta de todas las curvas de luz y  $\{1, \dots, M\}$  representa los posibles tipos de variabilidad estelar. Contamos con una muestra aleatoria de tamaño  $N$ , llamada muestra de entrenamiento,  $\mathcal{L} = \{(x_i, j_i), \dots, (x_N, j_N)\}$  con  $x_i \in X$  y  $j_i \in \{1, \dots, M\}$ , es decir, una muestra de  $X$  previamente clasificada. Nuestra tarea es entonces proponer una función  $g : X \rightarrow \{1, \dots, M\}$  a partir de la información contenida en  $\mathcal{L}$  que representa nuestra predicción de la clase a la que pertenece cada elemento de  $X$ . La función  $g$  se llama clasificador y, para un elemento  $x \in X$  cuya clase  $j$  es desconocida, el clasificador falla si  $g(x) \neq j$ .

El espacio  $X$  puede ser complejo o no estar matemáticamente bien de-

finido, por lo cual con frecuencia se representan los objetos con vectores, llamados de características, en  $\mathbb{R}^n$ . Por ejemplo si queremos realizar detección de rostros,  $X$  consiste de todos los posibles rostros, por lo que es más conveniente representar cada rostro con un conjunto de números como la separación de los ojos, el ángulo que forma las líneas que unen los ojos con la barbilla, etcétera; lo mismo sucede con las curvas de luz, por lo que representamos cada una con un vector. Estos vectores de características pueden, en principio, ser una combinación de variables continuas, discretas y categóricas, sin embargo esto no afecta en gran medida la teoría. Así las cosas, la elección de un clasificador puede ser una función  $g : \mathbb{R}^n \rightarrow \{1, \dots, M\}$ .

Se debe utilizar un marco probabilístico para modelar la dependencia entre características y clases. Puede suceder que dos observaciones con un mismo vector de características pertenezcan a clases diferentes. Esto puede suceder en escenarios en los que pertenencia a una u otra clase no sea completamente explicada por diferencias en los vectores de características, o porque la dependencia real entre características y clases sea no determinista. En este orden de ideas suponemos que existe una medida de probabilidad  $P$  sobre  $\mathbb{R}^n \times \{1, \dots, M\}$  tal que  $P(\vec{x}, j)$  es la probabilidad de observar un vector de características  $\vec{x} \in \mathbb{R}^n$  cuyo objeto representado pertenece a clase  $j$ . Así definimos la probabilidad de error del clasificador  $g$ ,  $P_e(g)$ , como

$$P_e(g) = P(g(\vec{x}) \neq j). \quad (2.1)$$

Surge entonces la pregunta de qué tan bueno puede ser un clasificador. El mejor clasificador posible es llamado el clasificador de Bayes.

## 2.2. El Clasificador de Bayes y Consistencia

Decimos que un clasificador  $g^* : \mathbb{R}^n \rightarrow \{1, \dots, M\}$  es de Bayes si minimiza la probabilidad de error, es decir, que si  $g$  es otro clasificador entonces

$$P_e(g^*) \leq P_e(g). \quad (2.2)$$

Llamaremos  $P_e^*$  a  $P_e(g^*)$ .

En el caso de que existan densidades condicionales  $f_j$  tales que para cada  $A \subset \mathbb{R}^n$  medible se cumple

$$P(A|j) = \int_A f_j(\vec{x}) d\vec{x} \quad (2.3)$$

podemos dar una expresión explícita para el clasificador de Bayes. Para un clasificador  $g$  podemos escribir

$$\begin{aligned}
 P_e(g) &= 1 - P(g(\vec{x}) = j) \\
 &= 1 - \sum_{j=1}^M P(g(\vec{x}) = j | j) P(j) \\
 &= 1 - \sum_{j=1}^M \left( \int_{\{g(\vec{x})=j\}} f_j(\vec{x}) d\vec{x} \right) P(j) \\
 &= 1 - \int \sum_{j=1}^M \chi_{\{g(\vec{x})=j\}} f_j(\vec{x}) P(j) d\vec{x}.
 \end{aligned} \tag{2.4}$$

Donde  $P(j)$  es la probabilidad *a priori* de encontrar un objeto de clase  $j$  y  $\chi_A$  es la función indicadora del conjunto  $A$ . Ahora, para cada  $\vec{x}$

$$\sum_{j=1}^M \chi_{\{g(\vec{x})=j\}} f_j(\vec{x}) P(j) \leq \max_j [f_j(\vec{x}) P(j)] \tag{2.5}$$

entonces

$$P_e(g) \geq 1 - \int \max_j [f_j(\vec{x}) P(j)] d\vec{x}. \tag{2.6}$$

Como la desigualdad 2.5 es igualdad cuando  $g$  le asigna a cada  $\vec{x}$  la clase  $j$  para la cual  $f_j(\vec{x}) P(j)$  es máximo, podemos concluir que éste es el clasificador de Bayes, es decir,

$$g^*(\vec{x}) = \arg \max_{j \in \{1, \dots, M\}} f_j(\vec{x}) P(j) \tag{2.7}$$

y

$$P_e^* = 1 - \int \max_j [f_j(\vec{x}) P(j)] d\vec{x}. \tag{2.8}$$

$g^*$  es el estimador de máxima verosimilitud para  $j$  y le asigna a cada  $\vec{x}$  la clase que hace que la observación  $\vec{x}$  sea más probable.

El hecho de que este clasificador sea el mejor posible nos muestra la importancia de elegir un vector de características de forma tal que las clases, es decir, sus distribuciones marginales  $f_j$  se superpongan lo menos posible en el espacio de características. Aunque esto es intuitivamente obvio, esto nos da un argumento para afirmarlo.  $f_j(\vec{x}) P(j)$  puede ser interpretado como la probabilidad de que el vector  $\vec{x}$  sea generado por la clase  $j$ . Si dos clases

generan puntos en una región del espacio  $n$ -dimensional con probabilidad parecida, al clasificar un punto en esa región se esperará una probabilidad de error alta. En el caso extremo en que se le asigna a cada objeto un vector constante, el clasificador 2.7 se reduce a escoger la clase que sea más probable *a priori*.

En realidad rara vez se conocen las distribuciones marginales  $f_j$  y frecuentemente no se conocen las probabilidades  $P(j)$ . Las probabilidades *a priori* pueden ser dadas por el analista o estimadas a partir de los datos si la muestra es representativa de  $X$ . Algunos métodos intentan estimar estas distribuciones marginales con funciones  $\tilde{f}_j$  y utilizar el clasificador

$$g(\vec{x}) = \arg \max_{j \in \{1, \dots, M\}} \tilde{f}_j(\vec{x}) P(j) \quad (2.9)$$

por ejemplo suponiendo alguna forma para las distribuciones  $f_j$  o utilizando métodos no paramétricos de estimación de densidades como estimación por núcleos. La estimación de densidades por núcleos ha probado ser útil porque se sabe que el estimador  $\tilde{f}_j$  de la densidad  $f_j$  converge en media cuadrática, es decir,

$$\int \left( f(\vec{x}) - \tilde{f}(\vec{x}) \right)^2 d\vec{x} \rightarrow 0 \text{ cuando } N \rightarrow \infty \quad (2.10)$$

sin embargo en dimensión  $d$  se ha demostrado que estos convergen a una velocidad de  $O(N^{1/(4+d)})$  (REVISAR Y CITA) por lo cual no son prácticos en dimensiones altas.

En la práctica, elegimos un clasificador entre una familia  $\mathcal{H}$  de clasificadores posibles, llamados hipótesis, mediante un algoritmo de aprendizaje. Por ejemplo un árbol de clasificación y regresión es un árbol binario de decisión con funciones sencillas de decisión en cada nodo; existe un algoritmo para escoger un árbol entre todos los árboles binarios posibles. Una manera natural de elegir este clasificador es minimizar la probabilidad de error empírica

$$\hat{P}_e(g) = \frac{1}{N} \sum_{i=1}^N \chi_{\{g(\vec{x}_i) \neq j_i\}}, \quad (2.11)$$

es decir, elegir el clasificador

$$g_{\mathcal{H},N}^* = \arg \min_{g \in \mathcal{H}} \hat{P}_e(g). \quad (2.12)$$

para el cual el error de clasificación es

$$P_{\mathcal{H},N}^* = \min_{g \in \mathcal{H}} \hat{P}_e(g). \quad (2.13)$$

Se dice que un clasificador elegido con el criterio 2.12 es consistente si  $P_{\mathcal{H},N}^* \rightarrow P_e^*$  cuando  $N \rightarrow \infty$ . Surge entonces la pregunta de bajo qué condiciones un clasificador es consistente. Es posible demostrar que las regla de decisión de  $k$  vecinos más cercanos [12], bosques aleatorios [2] y máquinas de soporte vectorial [41] son consistentes. La idea utilizar la minimización del error empírico para elegir clasificadores fue desarrollada por Vapnik y Chervonenkis (citadas están en p187 del Devroye, PONER). Para saber más, es posible consultar [12].

En aplicaciones no se conoce la probabilidad mínima de error  $P_e^*$  por lo que no es posible saber en términos absolutos qué tan bueno es un clasificador en un problema específico. Además de encontrar clasificadores que logren probabilidades tan bajas como sea posible, también es necesario implementar algoritmos de aprendizaje que sean eficientes y cuyos tiempos de ejecución no crezcan demasiado rápido con el tamaño de la muestra. Para juzgar un clasificador  $g$  es necesario estimar su probabilidad de error  $P_e(g)$ .

### 2.3. Estimación del Error

Uno de los métodos más populares para estimar la probabilidad de clasificación correcta de la función de decisión entrenada por un algoritmo de aprendizaje es validación cruzada de  $v$  iteraciones. Se divide la muestra  $\mathcal{L}$  en  $v$  muestras de prueba  $\mathcal{L}_k$ ,  $k = 1, \dots, v$  con el mismo número de elementos (o lo más próximo posible) y se define la  $k$ -ésima muestra de entrenamiento como  $\mathcal{L}^k = \mathcal{L} \setminus \mathcal{L}_k$ . Utilizando cada una de las  $v$  muestras de entrenamiento  $\mathcal{L}^k$  se puede entrenar una regla de decisión utilizando el algoritmo de aprendizaje en cuestión. Con ella se clasifican los elementos de la muestra de prueba  $\mathcal{L}^k$  y se calcula  $N_{ij}^k$  el número de elementos de la clase  $j$  clasificado como  $i$ . Sea  $N_{ij} = \sum_k N_{ij}^k$  el número total de elementos de la clase  $j$  clasificado como  $i$ . Es posible estimar la probabilidad de que un elemento de la clase  $j$  sea clasificado como  $i$ ,  $P^{VC}(g(\vec{x}) = i|j)$ , con  $N_{ij}/N_j$ , donde  $N_j$  es el número de elementos pertenecientes a la clase  $j$  en la muestra  $\mathcal{L}$ . Intuitivamente, si la muestra es grande tendremos aproximadamente el mismo poder para clasificar con la muestra completa que con una fracción  $\frac{v-1}{v}$  de ella, por lo cual  $P^{VC}$  será una

buena aproximación a la probabilidad real de clasificación. El valor  $v = 10$  es popular en la literatura aunque esta elección es un poco arbitraria. Una elección de  $v$  grande da estiamdos menos pesimistas de la probabilidad de error, sin embargo aumentar  $v$  aumenta el costo computacional del estimado, por lo que estos dos aspectos deben ser balanceados.

A continuación exponemos algunos clasificadores.

## 2.4. Clasificadores

### 2.4.1. K Vecinos Más Cercanos

K vecinos más cercanos (knn por sus iniciales en inglés) fue propuesto por Fix y Hodges en [13], y luego republicado en [28]. Se basa en el principio de que los ejemplos de una misma clase se encuentran cerca y que es posible clasificar uno basado en la observación de la clase de sus vecinos más cercanos<sup>1</sup>. Dado un entero  $k$  fijo, esta regla le asigna a cada punto de  $\mathbb{R}^n$  la clase a la que pertenecen la mayoría de los  $k$  elementos más cercanos a  $\vec{x}$  entre los elementos de la muestra  $\{\vec{x}_1, \dots, \vec{x}_N\}$ , esto es,

$$g^{knn}(x) = j \text{ tal que } \sum_{i=1}^N w_{i,N} \chi_{\{j_i=j\}} > \sum_{i=1}^N w_{i,N} \chi_{\{j_i=k\}} \forall k \neq j \quad (2.14)$$

donde  $w_{i,N} = 1/k$  si  $\vec{x}_i$  está entre los  $k$  vecinos más cercanos de  $\vec{x}$  y es 0 de lo contrario.  $w_{i,N}$  es llamado peso. Es posible demostrar que knn es consistente en el caso en que  $k/N \rightarrow 0$  cuando  $N \rightarrow \infty$  para cualquier elección de pesos  $w_{i,N}$  siempre y cuando no permita la clasificación en una clase con minoría numérica [12].

En primera aproximación, se puede implementar un algoritmo que clasifica un punto  $\vec{x}$  en un tiempo  $O(Nk)$ , sin embargo es posible crear estructuras de datos que hacen esta búsqueda más eficiente. Por ejemplo un COVER TREE (traducir)[1] es una estructura de datos que ocupa  $O(N)$  espacio, puede ser construida en un tiempo de  $O(N \log N)$  y permite realizar búsquedas en tiempo  $O(\log N)$  y ha mostrado aumentar la velocidad de las búsquedas entre uno y varios órdenes de magnitud con respecto a utilizar el algoritmo de fuerza bruta (Beygelzimer). Esta estructura se encuentra implementada en el paquete FNN (cite) para R.

---

<sup>1</sup>Dime con quién andas y te diré quién eres

Existen algunas variaciones de knn como knn empaquetado<sup>2</sup> [6, 4] y esquemas de pesos óptimos [24]. El proceso de empaquetado fue propuesto por [6, 4] y consiste en que, dado un punto  $\vec{x}$ , este es clasificado usando la regla de la mayoría entre  $n$  clasificadores de knn que utilizan submuestras de tamaño  $m < N$  tomadas de la muestra original con reemplazo. Este procedimiento ha mostrado aumentar la precisión de los clasificadores [4]. Por otra parte, puede demostrarse que la elección de pesos dada en la ecuación 2.14 es asintóticamente óptima, sin embargo hay situaciones en las que una elección de pesos puede mejorar la precisión. Por ejemplo [24] dio pesos óptimos para el caso en que la dimensión de los datos es 4.

### 2.4.2. Máquinas de Soporte Vectorial

Las Máquinas de Soporte Vectorial (MSV) son sistemas de clasificación que utilizan con conjunto de hipótesis las funciones lineales en un espacio de dimensión alta. Las MSV como se conocen hoy en día fueron propuestas por Cortes y Vapnik en [9] basado en utilizar núcleos para encontrar un plano que maximice la distancia a los puntos de la muestra, o equivalentemente, de margen maximal. Daremos una discusión sobre clasificadores lineales y clasificadores lineales de margen maximal, luego mencionamos los conceptos de optimización convexa que son la base de la utilización de núcleos para MSV y finalmente referenciamos el algoritmo de Minimización Secuencial Óptima. Seguimos el texto de Cristianini y Shawe-Taylor [10] en el que se puede encontrar una introducción completa a MSV y la teoría de optimización convexa necesaria para MSV. Para consultas sobre temas adicionales sobre optimización convexa, se puede consultar el libro de Boyd, Vandenberghe y Lieven [3].

Las MSV son clasificadores binarios, es decir, solo pueden distinguir entre dos clases. Para casos en los que se necesita clasificar más de dos clases, es posible implementar esquemas de votación que serán expuestos más adelante. Primero describimos los clasificadores lineales en  $\mathbb{R}^n$  en casos en los que se puede escoger un plano que separe perfectamente las dos clases y luego extendemos estos métodos para casos en lo que esto no es posible. Supongamos que se tiene un problema de clasificación binario donde el conjunto de las clases posibles es  $\{-1, 1\}$ . Consideremos clasificadores lineales de la forma

$$g(\vec{x}) = \text{signo}(\langle \vec{w}, \vec{x} \rangle + b). \quad (2.15)$$

---

<sup>2</sup>En inglés *bagged knn*. *Bagging* es una abreviación de *bootstrap aggregating*.



Una muestra de entrenamiento de tamaño  $N$   $\mathcal{L} = \{(\vec{x}_1, j_1), \dots, (\vec{x}_N, j_N)\}$  es linealmente separable si existe un plano definido por  $\langle \vec{w}, \vec{x} \rangle + b = 0$  tal que

$$j_i (\langle \vec{w}, \vec{x}_i \rangle + b) > 0, i = 1, \dots, N. \quad (2.16)$$

Nos referiremos al plano  $\langle \vec{w}, \vec{x} \rangle + b = 0$  con la notación abreviada  $(\vec{w}, b)$ .  $\vec{w}$  es el vector perpendicular al plano y la condición 2.16 corresponde a que los elementos de la clase 1 quedan ubicados en el semiespacio definido por  $\langle \vec{w}, \vec{x} \rangle + b > 0$ , mientras que los pertenecientes a la clase  $-1$  quedan en el semiespacio  $\langle \vec{w}, \vec{x} \rangle + b < 0$ . Este plano puede no estar bien definido, en el sentido de que puede haber más de un plano separador para un conjunto de datos, por lo que es necesario definir una noción de lo que significa elegir “el mejor” plano.

Podemos elegir el plano maximizando la distancia entre el plano y los ejemplos, por lo que es necesario definir la noción de margen. Definimos el margen funcional  $\gamma_i$  de un ejemplo  $(\vec{x}_i, j_i)$  con respecto al hiperplano  $(\vec{w}, b)$  como

$$\gamma_i = j_i (\langle \vec{w}, \vec{x}_i \rangle + b). \quad (2.17)$$

Un ejemplo  $(\vec{x}_i, j_i)$  es clasificado de manera correcta por el plano  $(\vec{w}, b)$  si  $\gamma_i > 0$  y nos referimos al mínimo de los márgenes funcionales de la muestra como el margen funcional de un plano. También podemos tomar el margen con respecto plano normalizado  $(\frac{\vec{w}}{\|\vec{w}\|}, \frac{b}{\|\vec{w}\|})$  en cuyo caso el margen funcional mide la distancia euclidiana entre el punto  $\vec{x}_i$  y el plano. En esta situación nos referiremos al margen como margen geométrico.

Como  $(\lambda \vec{w}, \lambda b)$  define el mismo plano que  $(\vec{w}, b)$  para todo  $\lambda \neq 0$ , tenemos un grado de libertad para elegir el plano separador. Podemos llevar a cabo un truco para expresar el margen funcional del plano en términos de la norma de  $\vec{w}$  y así traducir el problema de encontrar el plano a un problema de optimización. Por tener un grado de libertad, podemos maximizar el margen geométrico manteniendo el margen funcional fijo e igual a 1. En este caso, si  $\vec{w}$  es el vector que alcanza un margen funcional de 1 en el punto positivo  $\vec{x}^+$  y  $-1$  en el punto negativo  $\vec{x}^-$ , podemos calcular su margen geométrico de la siguiente forma. Como tener un margen funcional de  $\pm 1$  significa que  $\langle \vec{w}, \vec{x}^\pm \rangle + b = \pm 1$  tenemos que el margen geométrico  $\gamma$  del plano cumple

$$\begin{aligned} \gamma &= \frac{1}{2} \left( \left\langle \frac{\vec{w}}{\|\vec{w}\|}, \vec{x}^+ \right\rangle - \left\langle \frac{\vec{w}}{\|\vec{w}\|}, \vec{x}^- \right\rangle \right) \\ &= \frac{1}{\|\vec{w}\|} \end{aligned} \quad (2.18)$$

por lo que encontrar el plano que maximice el margen geométrico es equivalente a solucionar el problema de optimización

$$\begin{aligned} & \underset{\vec{w}, b}{\text{minimizar}} && \langle \vec{w}, \vec{w} \rangle \\ & \text{sujeto a} && j_i(\langle \vec{w}, \vec{x}_i \rangle + b) \geq 1, \quad i = 1, \dots, N, \end{aligned} \quad (2.19)$$

donde la restricción hace que el margen funcional de cada  $\vec{x}_i$  con respecto al plano sea mayor o igual que 1, porque elegimos el plano con margen 1. Así, podemos traducir el problema de encontrar el plano separador para una muestra linealmente separable con el problema de optimización convexa 2.19.

Hasta ahora solo hemos considerado situaciones en las que los datos  $(\vec{x}_i, j_i)$  son linealmente separables. Para permitir clasificaciones erróneas podemos introducir variables de holgura  $\xi_i > 0$  en el problema de optimización 2.19 para que los algunos ejemplos puedan ser clasificados erróneamente, es decir,  $j_i(\langle \vec{w}, \vec{x}_i \rangle + b) \geq 1 - \xi_i$ . También debemos introducir un costo asociado al vector de holgura  $\vec{\xi} = (\xi_1, \dots, \xi_N)$ , por lo que la función objetivo será una combinación del costo y la función objetivo original. En el caso en que se utilice la norma 1 del vector  $\vec{\xi}$ , el problema de optimización 2.19 se convierte en

$$\begin{aligned} & \underset{\vec{w}, b, \vec{\xi}}{\text{minimizar}} && \langle \vec{w}, \vec{w} \rangle + C \sum_i \xi_i, \\ & \text{sujeto a} && j_i(\langle \vec{w}, \vec{x}_i \rangle + b) \geq 1 - \xi_i, \\ & && \xi_i > 0, \\ & && i = 1, \dots, N, \end{aligned} \quad (2.20)$$

y al elegir la norma 2

$$\begin{aligned} & \underset{\vec{w}, b, \vec{\xi}}{\text{minimizar}} && \langle \vec{w}, \vec{w} \rangle + C \sum_i \xi_i^2, \\ & \text{sujeto a} && j_i(\langle \vec{w}, \vec{x}_i \rangle + b) \geq 1 - \xi_i, \\ & && \xi_i > 0, \\ & && i = 1, \dots, N, \end{aligned} \quad (2.21)$$

que es equivalente al mismo problema tras eliminar la restricción  $\xi_i > 0$ , esto es,

$$\begin{aligned} & \underset{\vec{w}, b, \vec{\xi}}{\text{minimizar}} && \langle \vec{w}, \vec{w} \rangle + C \sum_i \xi_i^2, \\ & \text{sujeto a} && j_i(\langle \vec{w}, \vec{x}_i \rangle + b) \geq 1 - \xi_i, \\ & && i = 1, \dots, N, \end{aligned} \quad (2.22)$$

donde  $C$  es un número que debe ser calibrado, utilizando estimaciones del error como validación cruzada. Elegimos la norma 2 como costo porque se pueden dar cotas para el error de generalización, esto es, el error cometido al clasificar ejemplos que no están incluidos en la muestra de aprendizaje, basadas en la norma 2 del vector de holgura  $\vec{\xi}$  (ver [10]), por lo que minimizar la norma 2 implica disminuir el error de generalización. El problema de optimización 2.19 es también un problema de optimización convexa.

La observación clave para la construcción del método de MSV es observar que el problema dual de 2.22 solo depende de el producto interno entre los datos  $\vec{x}_i, i = 1, \dots, N$ . Para ello es necesario definir el lagrangiano y el problema dual de un problema de optimización. Adicionalmente damos las condiciones de Karush-Kuhn-Tucker, que tienen como consecuencia el fenómeno que le da el nombre a MSV. Recordemos que para un problema de optimización de la forma

$$\begin{aligned} & \underset{\vec{w} \in \mathcal{D}}{\text{minimizar}} && f_0(\vec{w}) \\ & \text{sujeto a} && f_i(\vec{w}) \leq 0, i = 1, \dots, m, \\ & && h_i(\vec{w}) = 0, i = 1, \dots, p, \end{aligned} \quad (2.23)$$

podemos definir su lagrangiano

$$L(\vec{w}, \vec{\alpha}, \vec{\beta}) = f_0(\vec{w}) + \sum_{i=1}^m \alpha_i f_i(\vec{w}) + \sum_{i=1}^p \beta_i h_i(\vec{w}) \quad (2.24)$$

y su función dual

$$W(\vec{\alpha}, \vec{\beta}) = \inf_{\vec{w} \in \mathcal{D}} L(\vec{w}, \vec{\alpha}, \vec{\beta}) \quad (2.25)$$

para la cual se cumple

$$W(\vec{\alpha}, \vec{\beta}) \leq L(\vec{w}, \vec{\alpha}, \vec{\beta}) \leq f_0(\vec{w}) \quad (2.26)$$

siempre que  $\alpha_i \geq 0, i = 1, \dots, m$ . Como  $g$  es una cota inferior para  $f_0$ , podemos preguntar si maximizar  $g$  y minimizar  $f_0$  son problemas equivalentes. Por lo anterior consideramos el problema dual de optimización

$$\begin{aligned} & \underset{\vec{\alpha}, \vec{\beta}}{\text{maximizar}} && W(\vec{\alpha}, \vec{\beta}) \\ & \text{sujeto a} && \alpha_i \geq 0, i = 1, \dots, m. \end{aligned} \quad (2.27)$$

En general no se tiene que maximizar  $W$  y minimizar  $f_0$  sean problemas equivalentes. En el caso de que sí lo sean se dice que se hay dualidad fuerte.

Sin embargo, es posible probar que, para el caso en el que estamos interesados, en el que el problema es de la forma 2.23 con  $\mathcal{D}$  un dominio convexo<sup>3</sup>,  $f_0$  convexa<sup>4</sup> y  $f_1, \dots, f_m, h_0, \dots, h_p$  funciones afines<sup>5</sup> entonces hay dualidad fuerte.

Si el problema de optimización 2.23 es convexo, es decir, si  $f_0, \dots, f_m$  son funciones convexas y  $h_0, \dots, h_p$  son afines, en el caso de que  $f_0, \dots, f_m$  son diferenciables es posible demostrar que para que  $\vec{w}^*$  sea el punto óptimo de problema 2.23 es necesario y suficiente que exista  $(\vec{\alpha}^*, \vec{\beta}^*)$  que cumplan las condiciones de Karush-Kuhn-Tucker (KKT)

$$f_i(\vec{w}^*) \leq 0, \quad i = 1, \dots, m, \quad (2.28)$$

$$h_i(\vec{w}^*) = 0, \quad i = 1, \dots, p, \quad (2.29)$$

$$\alpha_i^* \geq 0, \quad i = 1, \dots, m, \quad (2.30)$$

$$\alpha_i^* f_i(\vec{w}^*) = 0, \quad i = 1, \dots, m, \quad (2.31)$$

$$\nabla f_0(\vec{w}^*) + \sum_{i=1}^m \alpha_i^* \nabla f_i(\vec{w}^*) + \sum_{i=1}^p \beta_i^* \nabla h_i(\vec{w}^*) = 0. \quad (2.32)$$

Ahora retomamos el problema original. El lagrangiano del problema 2.22 es

$$L(\vec{w}, b, \vec{\xi}, \vec{\alpha}) = \frac{1}{2} \langle \vec{w}, \vec{w} \rangle + \frac{C}{2} \sum_i^N \xi_i^2 + \sum_{i=1}^N \alpha_i [\gamma_i(\langle \vec{w}, \vec{x}_i \rangle + b) - 1 + \xi]. \quad (2.33)$$

Para calcular la función dual  $W$  calculamos los puntos críticos de  $L$

$$\frac{\partial L}{\partial \vec{w}} = \vec{w} - \sum_{i=1}^N j_i \alpha_i \vec{x}_i = \vec{0} \quad (2.34)$$

$$\frac{\partial L}{\partial \vec{\xi}} = C \vec{\xi} - \vec{\alpha} = \vec{0} \quad (2.35)$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^N j_i \alpha_i = 0 \quad (2.36)$$

<sup>3</sup>Un conjunto  $\mathcal{D} \subseteq \mathbb{R}^n$  es convexo si para todos  $d_1, d_2 \in \mathcal{D}$  se cumple  $\theta d_1 + (1-\theta)d_2 \in \mathcal{D}$

<sup>4</sup>Una función  $f(\vec{w})$  es convexa si  $f(\theta \vec{w}_1 + (1-\theta)\vec{w}_2) \leq \theta f(\vec{x}_1) + (1-\theta)f(\vec{x}_2)$  para cada  $\theta \in [0, 1]$

<sup>5</sup>Una función  $h(\vec{w})$  es afín si es de la forma  $h(\vec{w}) = A\vec{w} + \vec{v}$ , las funciones afines son convexas

con lo que obtenemos

$$W(\vec{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,k=1}^N j_i j_k \alpha_i \alpha_k \left( \langle \vec{x}_i, \vec{x}_k \rangle + \frac{1}{C} \delta_{ik} \right). \quad (2.37)$$

por lo que lo que el problema de optimización 2.22 es equivalente (por haber dualidad fuerte) al problema de optimización

$$\begin{aligned} & \underset{\vec{\alpha}}{\text{maximizar}} && \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,k=1}^N j_i j_k \alpha_i \alpha_k \left( \langle \vec{x}_i, \vec{x}_k \rangle + \frac{1}{C} \delta_{ik} \right) \\ & \text{sujeto a} && \sum_{i=1}^N j_i \alpha_i = 0, \\ & && \alpha_i \geq 0, i = 1, \dots, N, \end{aligned} \quad (2.38)$$

donde  $\delta_{ik}$  es la función delta de Kronecker,  $\delta_{ik} = 1$  si  $i = k$  y 0 de lo contrario. Si  $\alpha^*$  es la solución al problema 2.38, las condiciones 2.31, llamadas condiciones de complementariedad, que son en este caso

$$\alpha_i^* [j_i (\langle \vec{w}, \vec{x}_i \rangle + b) - 1 + \xi_i] = 0 \quad (2.39)$$

nos muestran que para los  $\vec{x}_i$  que se encuentran en el margen o mal clasificados  $\alpha_i \neq 0$  y de lo contrario  $\alpha_i = 0$ . Los vectores para los cuales  $\alpha_i \neq 0$  son llamados vectores de soporte porque el plano encontrado está únicamente determinado por ellos. Por esto, se dice que la solución es dispersa. Esto se puede ver en la ecuación 2.34, que muestra que los vectores de soporte son los únicos que aportan al vector  $\vec{w}$  que define el plano, esto es,

$$\vec{w} = \sum_{i=1}^N j_i \alpha_i^* \vec{x}_i = \sum_{i \in vs} j_i \alpha_i^* \vec{x}_i \quad (2.40)$$

donde  $i \in vs$  hace referencia a los  $\vec{x}_i$  que son vectores de soporte.  $b$  es escogido de tal manera que para los vectores de soporte su cumpla

$$j_i (\langle \vec{w}, \vec{x}_i \rangle + b) = 1 - \xi_i = 1 - \frac{\alpha_i^*}{C}, i \in vs \quad (2.41)$$

por las ecuaciones 2.39 y 2.35. Con lo anterior el clasificador 2.15 encontrado al solucionar el problema de optimización es

$$g(\vec{x}) = \text{signo} \left( \sum_{i \in vs} j_i \alpha_i^* \langle \vec{x}_i, \vec{x} \rangle + b \right) \quad (2.42)$$

cuyo margen geométrico  $\gamma = \frac{1}{\|\vec{w}\|}$  se puede calcular con

$$\begin{aligned}
\langle \vec{w}, \vec{w} \rangle &= \sum_{i,k \in vs} j_i j_k \alpha_i \alpha_k \langle \vec{x}_i, \vec{x}_k \rangle \\
&= \sum_{i \in vs} j_i \alpha_i \sum_{k \in vs} j_k \alpha_k \langle \vec{x}_i, \vec{x}_k \rangle \\
&= \sum_{i \in vs} \alpha_i^* (1 - \xi_i^* - j_i b^*) \\
&= \sum_{i \in vs} \alpha_i^* - \sum_{i \in vs} \alpha_i^* \xi_i^* \\
&= \sum_{i \in vs} \alpha_i^* - \frac{1}{C} \langle \vec{\alpha}^*, \vec{\alpha}^* \rangle
\end{aligned} \tag{2.43}$$

por lo cual

$$\gamma = \left( \sum_{i \in vs} \alpha_i^* - \frac{1}{C} \langle \vec{\alpha}^*, \vec{\alpha}^* \rangle \right)^{-1/2}. \tag{2.44}$$

Ahora tenemos todos los ingredientes necesarios para introducir el uso de núcleos para MSV. La observación central de MSV es que el problema de optimización 2.38 solo depende de los datos  $\vec{x}_1, \dots, \vec{x}_N$  a través de la matriz  $(\langle \vec{x}_i, \vec{x}_k \rangle)_{i,k=1}^N$ , llamada matriz de Gram. Si podemos calcular la matriz de Gram para una representación de los datos en un espacio con producto interno de dimensión mayor, podemos modificar el problema de optimización 2.22 para encontrar un plano separador en ese espacio. Sea  $\mathcal{H}$  un espacio de Hilbert con producto interno  $\langle \cdot, \cdot \rangle_{\mathcal{H}}$ , y  $\phi : \mathbb{R}^n \rightarrow \mathcal{H}$  una función. Si logramos encontrar una función  $K' : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$  tal que  $K'(\vec{x}, \vec{y}) = \langle \phi(\vec{x}), \phi(\vec{y}) \rangle_{\mathcal{H}}$  podemos resolver el problema de optimización equivalente a 2.38 para encontrar el plano de margen maximal en  $\mathcal{H}$  usando una representación de los datos en  $\mathcal{H}$  a través de  $\phi$ , es decir, resolver

$$\begin{aligned}
&\underset{\vec{\alpha}}{\text{maximizar}} && \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,k=1}^N j_i j_k \alpha_i \alpha_k K(\vec{x}_i, \vec{x}_k) \\
&\text{sujeto a} && \sum_{i=1}^N j_i \alpha_i = 0, \\
&&& \alpha_i \geq 0, i = 1, \dots, n.
\end{aligned} \tag{2.45}$$

con  $K(\vec{x}, \vec{y}) = K'(\vec{x}, \vec{y}) + \frac{1}{C} \delta(\vec{x}, \vec{y})$ , siendo  $\delta$  la función delta de Dirac,  $\delta(\vec{x}, \vec{y}) = 1$  si  $\vec{x} = \vec{y}$  y  $\delta(\vec{x}, \vec{y}) = 0$  de lo contrario. En analogía con 2.42, el clasificador obtenido al resolver el problema de optimización 2.45 es

$$g(\vec{x}) = \text{signo} \left( \sum_{i=1}^N j_i \alpha_i^* K(\vec{x}_i, \vec{x}) + b \right) \quad (2.46)$$

con  $b$  elegido como en 2.41 y margen geométrico 2.44.

Existe un teorema, debido a Mercer [16], que da las condiciones necesarias para que  $K(\vec{x}, \vec{y}) = \langle \phi(\vec{x}), \phi(\vec{y}) \rangle_{\mathcal{H}}$  para algún  $\phi$ , lo cual es computacionalmente eficiente puesto que evita la necesidad de conocer explícitamente el espacio  $\mathcal{H}$  y la función  $\phi$ . Tal función  $K$  es llamada núcleo. Para que  $K(\vec{x}, \vec{y})$  defina un producto interno es claro que debe ser definida positiva y simétrica. En el caso de dimensión finita, si  $K$  es una matriz simétrica semidefinida positiva, entonces podemos escribir  $K$  de la forma

$$K = \sum_i \lambda_i v_i v_i^T \quad (2.47)$$

por lo que, si escribimos  $\vec{x} = (x_1, \dots, x_n)$  y  $\vec{y} = (y_1, \dots, y_n)$  en la base normalizada de autovectores de  $K$ ,  $K$  define un producto interno  $\langle \cdot, \cdot \rangle_K$  dado por

$$K(\vec{x}, \vec{y}) = x^T K y = \sum_{i,j} \lambda_i x^T v_i v_i^T y = \sum_i \lambda_i x_i y_i = \langle x, y \rangle_K \quad (2.48)$$

siendo  $\vec{v}_i$  los autovectores de  $K$  y  $\lambda_i \geq 0$  sus autovalores. Análogamente, si  $\lambda_i$  y  $\phi_i$   $i = 1, 2, \dots$  son los autovalores y las autofunciones normalizadas del problema

$$\int K(\vec{x}, \vec{z}) \phi(\vec{z}) d\vec{z} = \lambda \phi(\vec{x}), \quad (2.49)$$

el teorema de Mercer da condiciones para que podamos escribir

$$K(\vec{x}, \vec{z}) = \sum_{i=1}^{\infty} \lambda_i \phi_i(\vec{x}) \phi_i(\vec{z}) = \langle \phi(\vec{x}), \phi(\vec{z}) \rangle_{\mathcal{H}} \quad (2.50)$$

para  $\phi(\vec{x}) = (\phi_1(\vec{x}), \phi_2(\vec{x}), \dots)$  y el producto interno definido por  $\langle \psi, \varphi \rangle_{\mathcal{H}} = \sum_{i=1}^{\infty} \lambda_i \psi_i \varphi_i$ . Sin ir en más detalle en el análisis, citamos el teorema.

**Teorema 1** (Mercer). *Sea  $X$  un subconjunto compacto de  $\mathbb{R}^n$ . Suponga que  $K$  es una función simétrica y continua tal que el operador integral  $T_K : L_2(X) \rightarrow L_2(X)$*

$$(T_K f)(\cdot) = \int_X K(\cdot, \vec{x}) f(\vec{x}) d\vec{x}$$

*es positivo, esto es,*

$$\int_{X \times X} K(\vec{x}, \vec{z}) f(\vec{x}) f(\vec{z}) d\vec{x} d\vec{z} \geq 0$$

*para todo  $f \in L_2(X)$ . Entonces podemos expandir  $K(\vec{x}, \vec{z})$  en una serie iniformente convergente en  $X \times X$  en términos de las autofunciones  $\phi_i \in L_2(X)$ , nor malizadas de tal forma que  $\|\phi_i\|_{L_2} = 1$  y autovalores positivos  $\lambda_i \geq 0$*

$$K(\vec{x}, \vec{z}) = \sum_{i=1}^{\infty} \lambda_i \phi_i(\vec{x}) \phi_i(\vec{z}).$$

Con las condiciones anteriores, podemos encontrar el núcleo  $K$ , para encontrar el plano de margen maximal en el  $\mathcal{H}$  resolviendo el problema de optimización 2.45 sin siquiera conocer explícitamente la función de representación  $\phi$  ni  $\mathcal{H}$ . Si  $K_1$ , y  $K_2$  son núcleos es posible demostrar que cualquier núcleo definifo por un polinomio de dos variables  $K(\vec{x}, \vec{z}) = p(K_1(\vec{x}, \vec{z}), K_2(\vec{x}, \vec{z}))$  también es un núcleo, así como  $K(\vec{x}, \vec{z}) = \exp(K_1(\vec{x}, \vec{z}))$ . Un núcleo popular es el núcleo radial

$$K(x, y) = e^{-\gamma \|\vec{x} - \vec{y}\|^2}, \quad (2.51)$$

que ha sido utilizado en gran variedad de aplicaciones [10]. Al utilizar el núcleo radial se debe calibrar tanto como el costo  $C$  y el ancho del núcleo  $\gamma$  para minimizar la tasa clasificación errónea utilizando, por ejemplo, validación cruzada.

En el caso de clasificación en  $M > 2$  categorías se pueden implementar esquemas de votación. Una posible aproximación, llamada uno-contra-uno<sup>6</sup>, es entrenar  $\frac{M(M-1)}{2}$  clasificadores que discriminen entre cada par de clases. Se escoge entonces la clase que haya sido decidida por la mayoría de clasificadores y en caso de empate se elige la que tenga índice menor. Otra aproximación, llamada uno-contra-resto<sup>7</sup> es entrenar  $M$  clasificadores que discriminen entre

---

<sup>6</sup>En inglés *one-against-one*

<sup>7</sup>En inglés *one-against-rest*



cada clase y su complemento. Se elige la clase en que de la clasificación con el mayor margen.

El problema 2.45 es un problema de optimización convexa. Estos problemas han sido estudiados extensamente y existen formas eficientes de encontrar las soluciones que pueden ser aplicadas directamente. El principal obstáculo para utilizar estas aproximaciones es que el espacio necesario para almacenar la matriz de Gram del problema crece cuadráticamente con el tamaño de la muestra dado que, en general, no es una matriz dispersa. Sin embargo se pueden explotar algunas características del problema, como el hecho de que la solución es dispersa para crear algoritmos eficientes.

Optimización Secuencial Minimal (OSM) es un algoritmo utilizado para resolver el problema de optimización 2.45. Se basa en el requerimiento de que  $\sum_i \alpha_i j_i = 0$  en todas las iteraciones del algoritmo, por lo que se deben actualizar a lo sumo dos  $\alpha_i$  en cada paso. En cada paso OSM utiliza eurísticas para elegir dos  $\alpha_i, \alpha_k$  para optimizar y utiliza el hecho de que este subproblema puede ser resuelto analíticamente, lo que elimina la necesidad de realizar operaciones con matrices. Este algoritmo logra reducciones en el tiempo de ejecución de varios órdenes de magnitud con respecto a algoritmos como el del gradiente. Existen implementaciones disponibles, como la librería libsvm escrita en C++ por Chih-Chung Chang and Chih-Jen Lin (cita libsvm) para la cual existe una interfaz para R en el paquete e1071 (cita e1071). Para clasificación en múltiples clases, libsvm utiliza el esquema de votación uno-contra-uno porque, basado en el análisis de (comparison, chinwei) los resultados con ambas aproximaciones son comparables y el método uno-contra-uno toma menos tiempo de entrenamiento.

### 2.4.3. Árboles de Clasificación y Regresión

Árboles de Clasificación y Regresión (CART, por sus siglas en inglés) es un método de clasificación que utiliza el conjunto de los árboles de decisión binarios como conjunto de hipótesis. Este método fue propuesto por Breiman, Friedman, Olshen y Stone a lo largo de varios trabajos, que luego fueron condesados en [5]. La metodología consiste en hacer crecer árboles de clasificación lo suficientemente grandes, creando nuevas ramas que maximicen cierto criterio de pureza de las divisiones, para luego podarlos y obtener un árbol que tenga las mejores propiedades de generalización posible ya que un árbol demasiado grande corre el riesgo de sobreajustarse a la muestra.

**2.4.4. Bosques Aleatorios**

# Capítulo 3

## Clasificación

Conociendo la curva de luz de un objeto podemos clasificarlo según su tipo de variabilidad estelar, sin embargo, esta relación no puede ser programada en un computador de manera sencilla. Cuando decimos que a cada curva de luz le corresponde un tipo de variabilidad estelar, queremos decir que existe una función, llamada función objetivo, cuya entrada es una curva de luz y cuya salida es un tipo de variabilidad estelar. El objetivo general del aprendizaje supervisado es aproximar esta función utilizando la experiencia previa. Esta experiencia previa es, en este caso, nuestro conjunto de datos (ver cuadro 3.1) y la estimación de esta regla, o función de decisión, es encontrada mediante un algoritmo de aprendizaje. Un algoritmo de aprendizaje escoge una función de decisión de un conjunto de funciones, llamado conjunto de hipótesis, utilizando un criterio que usualmente consiste en la minimización de una función de costo asociada a las clasificaciones erróneas. En nuestro caso utilizamos como función de costo la probabilidad de clasificación incorrecta.

Cada curva de luz en nuestra muestra es una tríada que consta de una sucesión de mediciones de magnitud, una sucesión de fechas y un tipo de variabilidad estelar. Como cada curva de luz tiene un número de mediciones diferentes que están repartidas en diferentes intervalos de tiempo, esto dificulta la implementación de algoritmos para entrenar una regla de decisión. En consecuencia, a cada curva de luz le asignamos un vector de dimensionalidad fija, llamado vector de características. Este vector puede ser, en principio, una combinación de variables categóricas y numéricas; en este trabajo le asignamos únicamente variables numéricas. La función de decisión divide el espacio de características en regiones tales que a cada elemento del espacio

de características le asigna un tipo de variabilidad estelar basado en qué región se encuentra. Así, para clasificar una curva cuyo tipo de variabilidad es desconocido, calculamos su vector de características y le asignamos la clase de variabilidad dada por la regla de decisión previamente entrenada. Por lo tanto la elección de características es crucial puesto que si los vectores de características de diferentes clases se superponen, no podrán ser distinguidos por la regla de decisión.

Subsecuentemente llamaremos  $g : \mathbb{R}^n \rightarrow \{VLP, \dots, BeEC\}$  a la función de decisión en cuestión que le asigna a cada vector de características un tipo de variabilidad (ver cuadro 3.2). Cada dato es representado por una pareja  $(\vec{x}, i)$ , con  $\vec{x} \in \mathbb{R}$  siendo el vector de características y  $i \in \{VLP, \dots, BeEC\}$  la clase a la que pertenece. La regla de decisión se equivoca si  $g(x) \neq i$ . Suponemos que existe una distribución de probabilidad  $p(\vec{x}, i)$  que representa la probabilidad de observar el vector de características  $\vec{x}$  con el tipo de variabilidad  $i$ .

Para estimar la probabilidad de clasificación correcta de la función de decisión entrenada por un algoritmo de aprendizaje utilizamos validación cruzada de  $v$  iteraciones. Para esto dividimos la muestra  $\mathcal{L}$  en  $v$  muestras de prueba  $\mathcal{L}_k$ ,  $k = 1, \dots, v$  con el mismo número de elementos (o lo más próximo posible) y definimos la  $k$ -ésima muestra de entrenamiento como  $\mathcal{L}^k = \mathcal{L} \setminus \mathcal{L}_k$ . Utilizando cada una de las  $v$  muestras de entrenamiento  $\mathcal{L}^k$  entrenamos una regla de decisión utilizando el algoritmo de aprendizaje en cuestión, con ella clasificamos los elementos de la muestra de prueba  $\mathcal{L}^k$  y calculamos  $N_{ij}^k$  el número de elementos de la clase  $j$  clasificado como  $i$ . Definimos  $N_{ij} = \sum_k N_{ij}^k$  el número total de elementos de la clase  $j$  clasificado como  $i$ . Estimamos la probabilidad de que un elemento de la clase  $j$  sea clasificado como  $i$ ,  $p^{VC}(g(\vec{x}) = i | j)$ , con  $N_{ij}/N_j$ , donde  $N_j$  es el número de elementos pretenecientes a la clase  $j$  en la muestra  $\mathcal{L}$ . Intuitivamente, si la muestra es grande tendremos aproximadamente el mismo poder para clasificar con la muestra completa que con una fracción  $\frac{v-1}{v}$  de ella, por lo cual  $p^{VC}$  será una buena aproximación a la probabilidad real de clasificación. Tomamos  $v = 10$  siguiendo la popularidad de este valor en la literatura.

La estimación de la probabilidad de que un elemento cualquiera sea clasificado correctamente, llamada precisión, será  $\sum_i p^{VC}(g(\vec{x}) = i | i) p(i)$ .  $p(i)$  es la probabilidad *a priori* de encontrar un objeto del tipo de variabilidad  $i$ . Como nuestra muestra no es representativa de las poblaciones de estrellas observadas y no existen estudios al respecto en la literatura para todos los tipos de variabilidad, tomamos  $p(i)$  uniforme, es decir,  $p(i) = 1/7$  para cada

$i$  (hay 7 tipos de variabilidad estelar en la muestra).

Utilizamos la maximización de la precisión como criterio para elegir la mejor función de decisión producida por cada algoritmo de aprendizaje. Adicionalmente analizamos para cada clase la sensibilidad  $p(g(\vec{x}) = i|i)$  (tasa de verdaderos positivos), la especificidad  $p(g(\vec{x}) \neq i|i^c)$  (tasa de verdaderos negativos), el poder de predicción positiva  $p(i|g(\vec{x}) = i)$  (probabilidad de que una vez clasificado, la clasificación sea correcta) y el poder de predicción negativa  $p(i^c|g(\vec{x}) \neq i)$ . El poder de predicción positiva juega un papel importante en este análisis puesto que, dada una nueva base de datos cuya clasificación no se conoce, si aplicamos el clasificador entrenado con nuestra muestra, esta es la estimación de la probabilidad de que esa clasificación sea correcta, lo cual corresponde a las situaciones reales que se encontrarán una vez se hagan públicos nuevas curvas de luz de estrellas variables sin clasificar.

### 3.1. El conjunto de Datos

Los datos utilizados en este trabajo provienen de la tercera fase del *Optical Gravitational Lensing Experiment* (OGLE-III). OGLE es un proyecto de larga duración cuyo objetivo principal es la búsqueda de materia oscura mediante el aprovechamiento de lentes gravitacionales. La tercera fase del proyecto comenzó en 2001 y hace uso de un telescopio de 1,3m de diámetro localizado en el observatorio de Las Campanas, Chile[42]. Uno de los principales resultados de OGLE-III es la reducción y publicación [43] de las curvas de luz de objetos en el bulbo de la Galaxia, la Gran Nube de Magallanes y la Pequeña Nube de Magallanes. En este trabajo utilizamos las curvas de luz de 431653 objetos del catálogo de estrellas variables de OGLE-III de seis tipos de variabilidad (ver tabla 3.1) al cual se puede acceder en la página del proyecto <sup>1</sup> y 475 curvas de luz de estrellas candidatas a ser clasificadas como Be (ESCRIBIR DE DÓNDE FUERON TOMADAS ESTAS).

Las curvas de luz tomadas del catálogo de estrellas variables de OGLE-III se encuentran clasificadas por tipo de variabilidad estelar en un proceso que que involucró, en una etapa, la inspección manual de las curvas de luz (ver referencias en la tabla 3.1) por lo cual tomaremos esta clasificación como verdadera. En este trabajo utilizamos únicamente las curvas de luz registradas en la banda I <sup>2</sup> a pesar de que también se encuentra disponible información

---

<sup>1</sup><http://ogle.astrouw.edu.pl/>

<sup>2</sup>Los objetos observados emiten radiación en una parte amplia del espectro electro-

Tipo de variabilidad y origen	Número de Objetos
RR Lyrae - BG [29]	16836
RR Lyrae - PNM [34]	2475
RR Lyrae - GNM [36]	24906
Cefeidas - BG [32]	32
Cefeidas - PNM [31]	4630
Cefeidas - GNM [30]	3361
Variables de Largo Periodo - BG [40]	232406
Variables de Largo Periodo - PNM [39]	19384
Variables de Largo Periodo - GNM [37]	91995
Sistema Binario Eclipsante - PNM [18]	6138
Sistema Binario Eclipsante - GNM [14]	26121
$\delta$ -Scuti - Nube Mayor de Magallanes [19]	2786
Cefeidas Tipo II - BG [33]	335
Cefeidas Tipo II - PNM [38]	43
Cefeidas Tipo II - GNM [35]	197
Candidata a Be - Vía Láctea (cita!)	475

Cuadro 3.1: Conjunto de datos utilizados. BG hace referencia al Bulbo Galáctico; PNM, a la Pequeña Nube de Magallanes y GNM, a la Gran Nube de Magallanes.

adicional sobre las curvas de luz como sus periodos y algunos coeficientes de Fourier (ver referencias en la tabla 3.1). Esta elección se debe a que el cálculo de estas cantidades es computacionalmente intensivo, no siempre se encuentran disponible y proponemos hacer la clasificación utilizando variables tomadas de estadística descriptiva.

Agrupamos los 432128 objetos disponibles en siete clases de variabilidad estelar (ver tabla 3.2). Esta elección de clases puede ser refinada puesto que en cada una de estas clases existen subclases. Por ejemplo entre las Cefeidas se puede distinguir entre aquellas que pulsan en su modo fundamental, en su primer sobretono (segundo armónico) o en su segundo sobretono (tercer armónico) (ver figura 3.1). Sin embargo conocer a qué clase de variabilidad

---

magnético. Los telescopios utilizan filtros para recoger solo la radiación emitida por estos objetos en ciertas partes del espectro electromagnético. El filtro I (infrarojo) tiene un ancho de banda de 149nm y una longitud de onda efectiva de 797nm (ver [15])

estelar pertenece un objeto facilita considerablemente su clasificación en subclases y análisis subsecuentes.

Tipo de Variabilidad	Cantidad
Variables de Largo Periodo (VLP)	343782
RR Lyrae (RRLyr)	44217
Cefeida (Cef)	8004
Sistema Binario Eclipsante (SBE)	32259
$\delta$ -Scuti ( $\delta$ Sct)	2788
Cefeida Tipo II (CefT2)	603
Candidata a Be (BeEC)	475
Total	432128

Cuadro 3.2: Cantidad de datos por tipo de variabilidad

En el Catálogo de Estrellas Variables de OGLE-III, cada curva de luz está disponible en un archivo que contiene tres columnas con los valores de magnitud, fecha juliana <sup>3</sup> en la que fue tomada cada medida y error en la medida de la magnitud. El número de medidas para cada objeto y la separación temporal varía ampliamente. La separación mínima dos mediciones en toda la muestra es de 0.00147d, la máxima es 2156.9d y en promedio están separadas por 5.1d; por su parte el número promedio de observaciones por objeto es 759; el máximo, 5173; y el mínimo, 11. El 75 % de los objetos cuenta con más de 386 observaciones. Para todos los objetos estas observaciones están repartidas en los (número de años) años en que estuvo activo OGLE-III. En la figura 3.2 se puede observar una curva de luz del catálogo de estrellas variables de OGLE-III.

## 3.2. Características Seleccionadas

Para una curva de luz denotaremos con  $(m_i)_{1 \leq i \leq n}$ ,  $(t_i)_{1 \leq i \leq n}$  y  $j$  a su serie de magnitudes, tiempos y tipo de variabilidad respectivamente.

Idealmente, el vector de características debe ser fácil de calcular y debe capturar las diferencias entre los tipos de variabilidad estelar. En la literatura [11, 25, 20] se han utilizado coeficientes de Fourier para este propósito. Suponiendo que los pares  $(t_i, m_i)$  provienen de una versión corrupta de la

<sup>3</sup>La fecha Juliana es el tiempo medido en días desde el 1 de enero de 4713 a. C.




Figura 3.1: Curvas de luz ilustrativas de Cefeidas en modo fundamental (izquierda), primer sobretono (mitad), segundo sobretono (derecha). Los números pequeños a la derecha de cada recuadro muestran los periodos redondeados de las curvas de luz presentadas en los recuadros. Tomado de [32]






Figura 3.2: Curva de luz de OGLE-LMC-CEP-2515 del catálogo OGLE-III. Los periodos en los que no hay mediciones corresponden a los momentos del año en los que la zona en la que se encuentra el objeto no puede ser observada debido a la posición relativa entre el Sol y la Tierra.

magnitud verdadera es posible encontrar estimadores de mínimos cuadrados para los coeficientes con el periodograma de Lomb-Scargle. Sea  $m(t)$  la magnitud verdadera de la estrella observada,  $y(t) = m(t) + \epsilon$  la medición que es una versión corrupta de  $m(t)$  con  $\epsilon$  siendo una variable aleatoria. Los autores de [11] encuentran los parámetros  $a_{ls}$ ,  $f_l$  y  $b_{ij}$  que mejor se ajustan a los datos de forma tal que  $y$  es estimada por  $\tilde{y}$

$$\tilde{y}(t) = \sum_{l=1}^3 \sum_{s=1}^4 (a_{ls} \sin 2\pi f_l s t + b_{ls} \cos 2\pi f_l s t) + b_0$$

Luego los autores utilizan estos coeficientes para dar una descripción de  $y(t)$  que es independiente de traslaciones temporales. Lo importante no es entrar en los detalles de esta elección de parámetros sino resaltar que la búsqueda de estos es computacionalmente intensiva. Los autores de [11] utilizan el periodograma de Lomb-Scargle [26] con el cual se obtiene una potencia para cada periodo posible. Predefinir los periodos posibles es un reto si no se tiene más información que la curva de luz de un objeto. Por ejemplo para clasificar las curvas de luz de Cefeidas Clásicas para el catálogo de OGLE-III [30] los autores probaron frecuencias entre 0.0 y 24.0 ciclos por día en au-

mentos de frecuencias de 0.0001 para 32 millones de objetos, para lo cual utilizaron supercomputadores del *Centre for Mathematical and Computational Modeling* de la Universidad de Varsovia, seguido de un análisis que llevó a la inspección manual de decenas de miles de curvas de luz. En este trabajo, basado en los hallazgos de [21] y [23], proponemos utilizar en lugar de estos coeficientes, variables descriptivas de la serie de magnitudes (ver tabla 3.3) que pueden ser calculadas en tiempos abrumadoramente menores, con menos poder computacional y sin intervención manual.

Cantidad	Fórmula
Media	$\mu = \frac{1}{n} \sum_i m_i$
Desviación estándar	$\sigma = \sqrt{\frac{1}{n} \sum_i (m_i - \mu)^2}$
Sesgo	$\frac{1}{n} \sum_i \left( \frac{m_i - \mu}{\sigma} \right)^3$
Curtosis	$\frac{1}{n} \sum_i \left( \frac{m_i - \mu}{\sigma} \right)^4$
Rango	$\max_i m_i - \min_i m_i$
Variación cuadrática	$\frac{1}{n} \sum_i (m_i - m_{i-1})^2$
Valor Abbe [17]	$\mathcal{A} = \frac{n}{2(n-1)} \frac{\sum_i (m_i - m_{i-1})^2}{\sum_i (m_i - \mu)^2}$
Abbe promedio [17]	$\bar{\mathcal{A}}_t$
Entropía de Shannon [27]	$\sum_i -p_i \log_2 p_i$
Entropía de Rényi[22]	$\frac{1}{1-\alpha} \log_2 \sum_x p_i^\alpha$

Cuadro 3.3: Variables utilizadas

Bajo este punto de vista, las magnitudes son vistas como una variable aleatoria independiente del tiempo y las cantidades de la tabla 3.3 son variables descriptivas de su densidad. En la figura 3.3 se observa una curva de luz y la densidad estimada de sus magnitudes. Al utilizar la distribución de la serie de magnitudes se asume que el número de observaciones es lo suficientemente grande, que estas son hechas en intervalos que evitan el aliasing y que son hechas durante más de un periodo del objeto observado. Es de esperar que las curvas que tienen formas similares, es decir, que pertenecen al mismo tipo de variabilidad estelar, tengan densidades de magnitudes similares y que, por ende, los parámetros descriptivos utilizados también sean similares.

La media  $\mu$  y la desviación estándar  $\sigma$  (ver cuadro 3.3) son variables descriptivas bien conocidas. En este caso la media es el valor al rededor del cual la serie de magnitudes oscila y la desviación una medida de la amplitud de estas oscilaciones. (Dar argumentos astronómicos). La figura 3.4 muestra




Figura 3.3: Curva de luz OGLE-LMC-CEP-0503 y densidad estimada de las magnitudes.

la densidad de cada una de las clases en el plano  $\mu$ - $\sigma$ . Aunque las diferentes clases se superponen en este plano, hay pares de clases que pueden ser distinguidas como  $\delta$ Sct y RRLyr.

Basado en el trabajo de [21] utilizamos el sesgo y la curtosis como características. El sesgo es el tercer momento central estandarizado <sup>4</sup> y es una medida de la asimetría de una distribución. Una distribución es simétrica si su sesgo es 0, su cola izquierda es más larga si su sesgo es positivo y su cola derecha es más larga si su sesgo es negativo. Por su parte la curtosis es el cuarto momento central estandarizado. Es una medida de qué tan concentrada está la distribución al rededor de la media. La curtosis de una distribución normal es 3 y con frecuencia se estudia una cantidad llamada exceso de curtosis que es el resultado de restarle 3 a la curtosis. Los autores de [21] encontraron que algunos tipos de variabilidad estelar podían ser distinguidos utilizando clasificadores lineales en el plano sesgo-curtosis.

Dado que la estimación de el sesgo y la curtosis con las fórmulas del cuadro 3.3 requiere de calcular las potencias  $(\mu - m_i)^3$  y  $(\mu - m_i)^4$ , son propensas a dar estimaciones erróneas en el caso de que existan datos atípicos. Calculamos

<sup>4</sup>El k-ésimo momento centrado de una variable aleatoria  $X$  (o de su distribución) es  $\mu_k = E[(X - \mu)^k]$ , siendo  $\mu$  su media. Su k-ésimo momento central estandarizado es  $\frac{\mu_k}{\sigma^k}$ , siendo  $\sigma$  la desviación estándar.




Figura 3.4

también la l-curtosis y el l-sesgo<sup>5</sup> y reemplazando el sesgo y la curtosis por estas cantidades no encontramos diferencias importantes en el poder para clasificar de los clasificadores que utilizamos. Esto puede ser un indicador de que no existe una proporción grande de datos atípicos en las curvas de luz. Por su simplicidad utilizamos el sesgo y la curtosis.

Cuadro 3.4:  $k = 1$ 

	becand	cep	dcst	ebs	lpv	rrlyr	t2cep
becand	381	1	0	50	41	0	0
cep	1	6595	4	172	54	986	87
dcst	0	7	2064	340	13	151	0
ebs	51	184	536	30129	573	668	29
lpv	42	187	19	944	342740	371	158
rrlyr	0	971	165	595	308	41911	217
t2cep	0	59	0	29	53	130	112

Cuadro 3.5:  $k=1$ , validación cruzada de 10 iteraciones

	becand	cep	dcst	ebs	lpv	rrlyr	t2cep
becand	0.80	0.00	0.00	0.00	0.00	0.00	0.00
cep	0.00	0.82	0.00	0.01	0.00	0.02	0.14
dcst	0.00	0.00	0.74	0.01	0.00	0.00	0.00
ebs	0.11	0.02	0.19	0.93	0.00	0.02	0.05
lpv	0.09	0.02	0.01	0.03	1.00	0.01	0.26
rrlyr	0.00	0.12	0.06	0.02	0.00	0.95	0.36
t2cep	0.00	0.01	0.00	0.00	0.00	0.00	0.19

### 3.3. Clasificación

#### 3.3.1. K Vecinos Más Cercanos

#### 3.3.2. Árboles de clasificación y regresión

#### 3.3.3. Máquinas de Soporte Vectorial

#### 3.3.4. Bosques Aleatorios

---

<sup>5</sup>Los l-momentos son combinaciones lineales de los estadísticos de orden. Son robustos, toman valores entre 0 y 1, y la interpretación de sus valores es análoga a la de los momentos. De la misma manera en que se define el sesgo y la curtosis muestral, es posible definir la l-curtosis y el l-sesgo. Fueron propuestos en (cita l-momentos) y su cálculo fue realizado utilizando el paquete lmoments(cita paquete l-moments) para R

Cuadro 3.6: Matriz de confusión para CART

	becand	cep	dcst	ebs	lpv	rrlyr	t2cep
becand	470	12	6	1039	8906	47	18
cep	0	6210	12	18	320	3098	92
dcst	0	35	2511	5538	91	1615	1
ebs	0	1	148	21346	346	64	1
lpv	5	107	24	1762	304810	100	3
rrlyr	0	648	82	552	13880	34313	92
t2cep	0	991	5	2004	15429	4980	396

Cuadro 3.7: Tasas de clasificación estimadas por validación cruzada de 10 iteraciones

	becand	cep	dcst	ebs	lpv	rrlyr	t2cep
becand	0.99	0.00	0.00	0.03	0.03	0.00	0.03
cep	0.00	0.78	0.00	0.00	0.00	0.07	0.15
dcst	0.00	0.00	0.90	0.17	0.00	0.04	0.00
ebs	0.00	0.00	0.05	0.66	0.00	0.00	0.00
lpv	0.01	0.01	0.01	0.05	0.89	0.00	0.00
rrlyr	0.00	0.08	0.03	0.02	0.04	0.78	0.15
t2cep	0.00	0.12	0.00	0.06	0.04	0.11	0.66

Cuadro 3.8:  $\gamma = 0,1$ , costo = 16

	becand	cep	dcst	ebs	lpv	rrlyr	t2cep
becand	297	0	2	26	16	0	0
cep	0	4622	0	55	85	788	69
dcst	0	0	1683	163	4	47	0
ebs	89	48	865	29439	198	563	5
lpv	89	490	22	1380	342823	1113	255
rrlyr	0	2844	216	1196	656	41706	274
t2cep	0	0	0	0	0	0	0







# Bibliografía

- [1] Alina Beygelzimer, Sham Kakade, and John Langford. Cover trees for nearest neighbor. In *Proceedings of the 23rd international conference on Machine learning*, pages 97–104. ACM, 2006.
- [2] Gérard Biau, Luc Devroye, and Gábor Lugosi. Consistency of random forests and other averaging classifiers. *The Journal of Machine Learning Research*, 9:2015–2033, 2008.
- [3] Stephen Boyd and Lieven Vandenberghe. *Convex optimization*. Cambridge university press, 2004.
- [4] Leo Breiman. Bagging predictors. *Machine learning*, 24(2):123–140, 1996.
- [5] Leo Breiman, Jerome Friedman, Charles J. Stone, and R. A. Olshen. *Classification and Regression Trees*. Chapman and Hall/CRC, New York, N.Y., 1 edition edition, January 1984.
- [6] Leo Breiman and others. Heuristics of instability and stabilization in model selection. *The annals of statistics*, 24(6):2350–2383, 1996.
- [7] BSJ. Types of Variables, June 2012.
- [8] Pablo M. Cincotta, Mariano Mendez, and Josue A. Nuñez. Astronomical time series analysis. I. A search for periodicity using information entropy. *The Astrophysical Journal*, 449:231, 1995.
- [9] Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine learning*, 20(3):273–297, 1995.

- [10] Nello Cristianini and John Shawe-Taylor. *An introduction to support vector machines and other kernel-based learning methods*. Cambridge university press, 2000.
- [11] Jonas Debosscher, L. M. Sarro, Conny Aerts, J. Cuypers, Bart Vandenbussche, R. Garrido, and E. Solano. Automated supervised classification of variable stars-I. Methodology. *Astronomy & Astrophysics*, 475(3):1159–1183, 2007.
- [12] Luc Devroye. *A probabilistic theory of pattern recognition*, volume 31. Springer Science & Business Media, 1996.
- [13] Evelyn Fix and Joseph L. Hodges Jr. Discriminatory analysis-nonparametric discrimination: consistency properties. Technical report, DTIC Document, 1951.
- [14] D. Graczyk, I. Soszyński, R. Poleski, G. Pietrzyński, A. Udalski, M. K. Szymański, M. Kubiak, L. Wyrzykowski, and K. Ulaczyk. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. XII. Eclipsing Binary Stars in the Large Magellanic Cloud. *Acta Astronomica*, 61:103–122, June 2011.
- [15] Hannu Karttunen, Pekka Kröger, Heikki Oja, Markku Poutanen, and Karl Johan Donner, editors. *Fundamental Astronomy*. Springer, Berlin ; New York, 5th edition edition, August 2007.
- [16] James Mercer. Functions of positive and negative type, and their connection with the theory of integral equations. *Philosophical transactions of the royal society of London. Series A, containing papers of a mathematical or physical character*, pages 415–446, 1909.
- [17] N. Mowlavi. Searching transients in large-scale surveys. A method based on the Abbe value. *Astronomy and Astrophysics*, 568:78, 2014.
- [18] M. Pawlak, D. Graczyk, I. Soszyński, P. Pietrukowicz, R. Poleski, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, L. Wyrzykowski, K. Ulaczyk, S. Kozłowski, and J. Skowron. Eclipsing Binary Stars in the OGLE-III Fields of the Small Magellanic Cloud. *Acta Astronomica*, 63:323–338, September 2013.

- [19] R. Poleski, I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, L. Wyrzykowski, O. Szewczyk, and K. Ulaczyk. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. VI. Delta Scuti Stars in the Large Magellanic Cloud. *Acta Astronomica*, 60:1–16, March 2010.
- [20] Joseph W. Richards, Dan L. Starr, Nathaniel R. Butler, Joshua S. Bloom, John M. Brewer, Arien Crellin-Quick, Justin Higgins, Rachel Kennedy, and Maxime Rischard. On Machine-learned Classification of Variable Stars with Sparse and Noisy Time-series Data. *The Astrophysical Journal*, 733(1):10, May 2011.
- [21] Bayron Stevenson Rodríguez Feliciano and José Alejandro García Varela. *Análisis estadístico en poblaciones de estrellas variables*. Tesis (Físico). Universidad de los Andes. Bogotá : Uniandes, 2012., 2012.
- [22] Alfréd Rényi and others. On Measures of Entropy and Information. In *Proceedings of the Fourth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Contributions to the Theory of Statistics*. The Regents of the University of California, 1961.
- [23] B. E. Sabogal, A. García-Varela, and R. E. Mennickent. Search for Southern Galactic Be Star Candidates. *Publications of the Astronomical Society of the Pacific*, 126:219–226, 2014.
- [24] Richard J. Samworth. Optimal weighted nearest neighbour classifiers. *The Annals of Statistics*, 40(5):2733–2763, October 2012.
- [25] L. M. Sarro, Jonas Debosscher, M. López, and Conny Aerts. Automated supervised classification of variable stars-II. Application to the OGLE database. *Astronomy & Astrophysics*, 494(2):739–768, 2009.
- [26] Jeffrey D. Scargle. Studies in astronomical time series analysis. II-Statistical aspects of spectral analysis of unevenly spaced data. *The Astrophysical Journal*, 263:835–853, 1982.
- [27] C.E. Shannon. A mathematical theory of communication. *Bell System Technical Journal*, The, 27(3):379–423, July 1948.

- [28] Bernard W. Silverman and M. Christopher Jones. E. Fix and JL Hodges (1951): An important contribution to nonparametric discriminant analysis and density estimation: Commentary on Fix and Hodges (1951). *International Statistical Review/Revue Internationale de Statistique*, pages 233–238, 1989.
- [29] I. Soszyński, W. A. Dziembowski, A. Udalski, R. Poleski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, S. Kozłowski, and P. Pietrukowicz. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. XI. RR Lyrae Stars in the Galactic Bulge. *Acta Astronomica*, 61:1–23, March 2011.
- [30] I. Soszyński, R. Poleski, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, O. Szewczyk, and K. Ulaczyk. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. I. Classical Cepheids in the Large Magellanic Cloud. *Acta Astronomica*, 58:163–185, September 2008.
- [31] I. Soszyński, R. Poleski, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, O. Szewczyk, and K. Ulaczyk. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. VII. Classical Cepheids in the Small Magellanic Cloud. *Acta Astronomica*, 60:17–39, March 2010.
- [32] I. Soszyński, A. Udalski, P. Pietrukowicz, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, R. Poleski, and S. Kozłowski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. XIV. Classical and Type II Cepheids in the Galactic Bulge. *Acta Astronomica*, 61:285–301, December 2011.
- [33] I. Soszyński, A. Udalski, P. Pietrukowicz, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, R. Poleski, and S. Kozłowski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. Type II Cepheids in the Galactic Bulge - Supplement. *Acta Astronomica*, 63:37–40, March 2013.
- [34] I. Soszyński, A. Udalski, M. K. Szymański, J. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, and R. Poleski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. IX. RR

- Lyr Stars in the Small Magellanic Cloud. *Acta Astronomica*, 60:165–178, September 2010.
- [35] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, O. Szewczyk, K. Ulaczyk, and R. Poleski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. II. Type II Cepheids and Anomalous Cepheids in the Large Magellanic Cloud. *Acta Astronomica*, 58:293, December 2008.
- [36] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, O. Szewczyk, K. Ulaczyk, and R. Poleski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. III. RR Lyrae Stars in the Large Magellanic Cloud. *Acta Astronomica*, 59:1–18, March 2009.
- [37] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, O. Szewczyk, K. Ulaczyk, and R. Poleski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. IV. Long-Period Variables in the Large Magellanic Cloud. *Acta Astronomica*, 59:239–253, September 2009.
- [38] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, and R. Poleski. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. VIII. Type II Cepheids in the Small Magellanic Cloud. *Acta Astronomica*, 60:91–107, June 2010.
- [39] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, R. Poleski, S. Kozłowski, and P. Pietrukowicz. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. XIII. Long-Period Variables in the Small Magellanic Cloud. *Acta Astronomica*, 61:217–230, September 2011.
- [40] I. Soszyński, A. Udalski, M. K. Szymański, M. Kubiak, G. Pietrzyński, Ł. Wyrzykowski, K. Ulaczyk, R. Poleski, S. Kozłowski, P. Pietrukowicz, and J. Skowron. The Optical Gravitational Lensing Experiment. The OGLE-III Catalog of Variable Stars. XV. Long-Period Variables in the Galactic Bulge. *Acta Astronomica*, 63:21–36, March 2013.

- [41] Ingo Steinwart. Consistency of support vector machines and other regularized kernel classifiers. *Information Theory, IEEE Transactions on*, 51(1):128–142, 2005.
- [42] A. Udalski. The Optical Gravitational Lensing Experiment. Real Time Data Analysis Systems in the OGLE-III Survey. *Acta Astron.*, 53(astroph/0401123):291, 2004.
- [43] A. Udalski, M. K. Szymanski, I. Soszynski, and R. Poleski. The Optical Gravitational Lensing Experiment. Final Reductions of the OGLE-III Data. *Acta Astronomica*, 58:69–87, 2008.